

Manual de Estudio: AWS Certified AI Practitioner

Dominio 3.3: Entrenamiento y Refinamiento de Modelos Fundacionales

Material de Preparación Detallado

1. Estrategias de Entrenamiento

El ciclo de vida de un Modelo Fundacional (FM) implica tres niveles de entrenamiento según el objetivo:

1.1. 1. Entrenamiento Previo (Pre-training)

Es la fase inicial donde el modelo aprende las capacidades básicas del lenguaje humano.

- **Datos:** Cantidad masiva (petabytes) de datos no estructurados.
- **Método:** Aprendizaje **autosupervisado**.
- **Recursos:** Requiere millones de GPUs, billones de tokens y mucho tiempo.

1.2. 2. Refinamiento (Fine-tuning)

Proceso para adaptar un modelo ya entrenado a una tarea o dominio específico.

- **Método:** Aprendizaje **supervisado** mediante ejemplos etiquetados.
- **Objetivo:** Actualizar las ponderaciones (weights) del modelo para mejorar en una tarea concreta.

1.3. 3. Entrenamiento Previo Continuo

Consiste en seguir entrenando el modelo con datos no etiquetados de dominios específicos (ej. jerga médica o legal).

- **Amazon Bedrock:** Permite el preentrenamiento continuo para modelos como *Amazon Titan Text Express* y *Lite*.

2. Desafíos Técnicos: Olvido Catastrófico

El **olvido catastrófico** ocurre cuando el proceso de refinamiento para una tarea específica modifica tanto las ponderaciones que el modelo pierde su capacidad de generalizar o realizar otras tareas que antes sabía hacer.

- **Mitigación:** El **refinamiento multitarea** (entrenar con ejemplos de varias tareas a la vez) ayuda a prevenir este efecto.

3. Técnicas de Refinamiento Eficiente (PEFT)

El refinamiento completo actualiza todos los parámetros del modelo, lo cual es costoso en memoria y computación. Las técnicas PEFT (*Parameter-Efficient Fine-Tuning*) solucionan esto:

1. **Congelación de Parámetros:** Se mantienen fijas las ponderaciones originales del modelo y solo se entrena una pequeña cantidad de capas adicionales.
2. **LoRA (Low-Rank Adaptation):** Es la técnica más popular. Crea matrices de "bajo rango" que se entrenan en cada capa del transformer mientras el modelo base permanece congelado.
3. **ReFT (Representation Fine-tuning):** En lugar de cambiar los pesos, aprende intervenciones en las representaciones ocultas de la red neuronal.

4. Alineación con Preferencias Humanas (RLHF)

El **RLHF** (*Reinforcement Learning from Human Feedback*) utiliza el aprendizaje por refuerzo y la retroalimentación de humanos para:

- Alinear el modelo con los valores humanos (honestidad, amabilidad, inocencia).
- Reducir la toxicidad y las respuestas perjudiciales.

5. Preparación de Datos y Herramientas AWS

El éxito del refinamiento depende de la calidad de los datos recopilados y organizados.

5.1. Ecosistema AWS para Datos de IA

Servicio	Función
SageMaker Canvas	Preparación de datos con flujos <i>no-code</i> (sin código).
SageMaker Ground Truth	Gestión de flujos de trabajo para etiquetado humano.
SageMaker Feature Store	Repositorio centralizado para buscar y recuperar características estandarizadas.
SageMaker Clarify	Detección de sesgos (género, raza, edad) en los datos de entrenamiento.
AWS Glue / Spark	Preparación de datos a gran escala y de forma <i>serverless</i> .

5.2. Modelos Específicos en AWS

- **SageMaker JumpStart:** Permite refinar modelos de lenguaje (especialmente de generación de texto) con datasets específicos de dominio.

6. Resumen del Proceso de Ajuste

1. **División del Dataset:** El conjunto de instrucciones se divide en **Entrenamiento**, **Validación** y **Prueba**.
2. **Cálculo de Pérdida:** Durante el ajuste, se comparan las finalizaciones del modelo con las etiquetas reales para calcular la "pérdida" y actualizar los pesos.
3. **Evaluación Final:** Se usa el dataset de retención" (*holdout*) para obtener la exactitud final del modelo refinado.